HEG-796-22-030

PREMIS et SHACL

Jan Krause-Bilvin

2022-05-02

Thème de cette session

— Ontologie de préservation (PREMIS)
— Schémas de grahes RDF (SHACL)

Cours précédents

— Linked Data Platform (LDP):
  — Ressources (ldp:Ressource) de type RDF et non-RDF
  — Conteneurs (ldp:Container), peuvent être emboîtés.
  — Manipulation via verbes HTTP:
    — GET: lire
    — POST / PUT : créer / mettre à jour
    — DELETE : effacer
— Les conteneurs LDP permettent de délimiter les ressources représantant des objets (métier, archivistiques).
  — Combinaison d'ontologies, p.ex. RiC-O, SKOS et autres
  — Fedora Commons accepte tout turtle valide (ressources RDF)

PREMIS

PREservation Metadata : Implementation Strategies (PREMIS) permet de représenter:

— les objets (p.ex. records),
— les événements (de préservation),
— les agents (personnes, logiciels) impliqués dans ces événement,
— les droits.

en RDF.

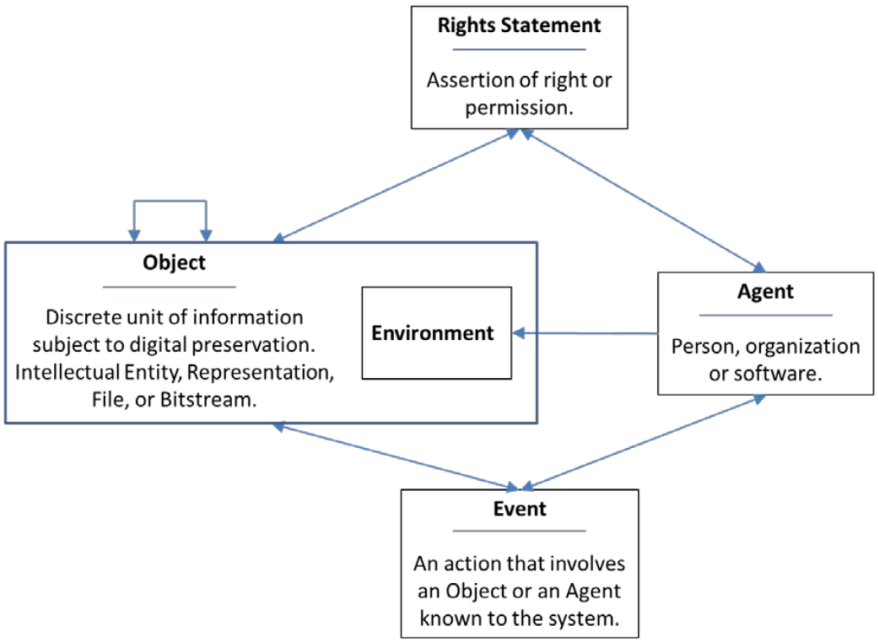

FIGURE 1 – PREMIS overview

Une représentation fine des objets numériques est disponible.

Exemple / demonstration : docuteam Packer (logiciel libre)

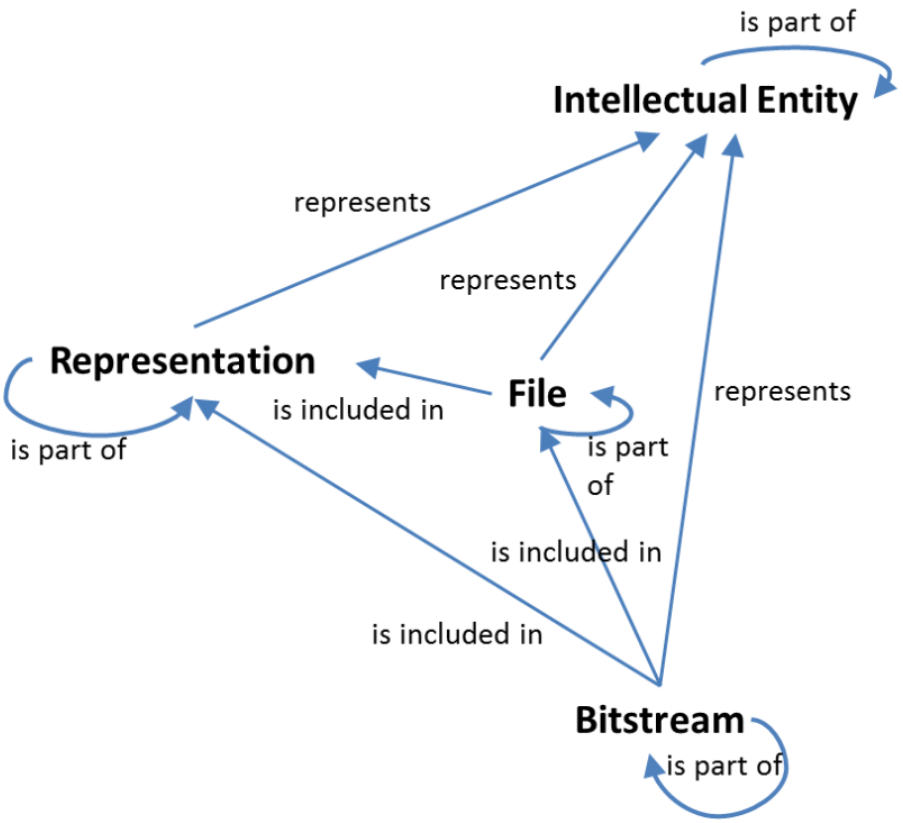

FIGURE 2 – PREMIS overview

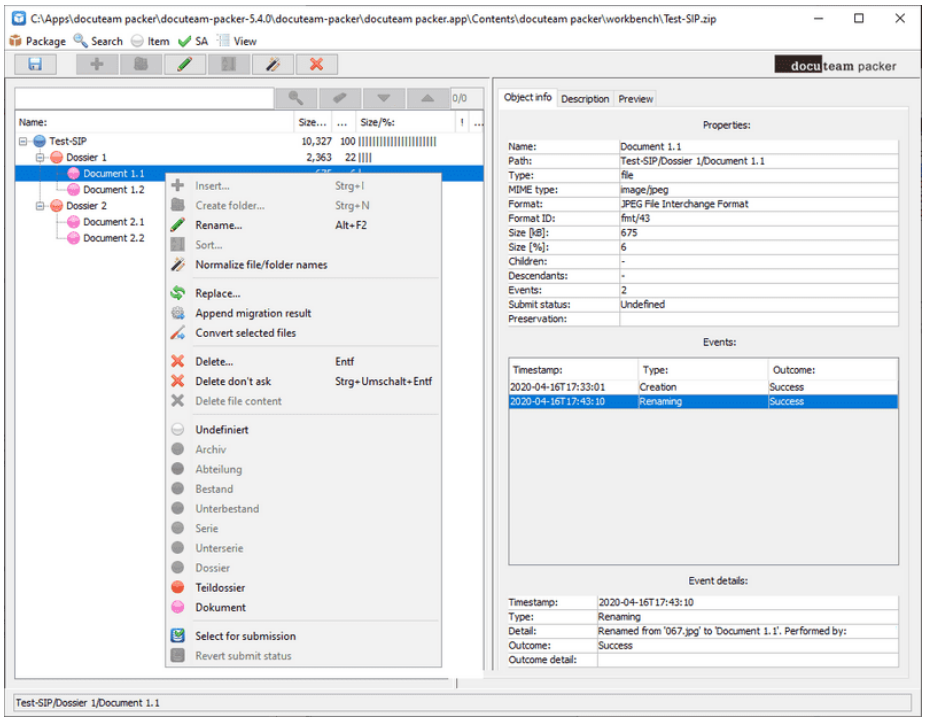

Exemples de concepts PREMIS:

- premis:hasMessageDigest (checksum)
- premis:signature (signature numérique)
- premis:hasSize (taille en octets)
- premis:orginalName (nom original)
- premis:rights (droits)
- premis:formatRegistry (format de fichier)
- premis:creatingApplication (application)
- premis:environmentDesignatinon (système)
- premis:inhibitors (inhibiteurs t.q. DRM ou chiffrement, cf. DLCM)
- premis:hasCompositionLevel (composition)

PREMIS peut être combiné aux ontologies descriptives pour assurer la préservation numérique. Par exemple:

PREMIS	RiC-O
-	RecordSet RiC-E03
Intellectual entity	Record RiC-E04
Representation	Instantiation RiC-E06

PREMIS	RiC-O
File	-
Datastream	-

Mais comment faire en pratique?

SHACL (Core)

SHape and Constraint Language (W3C)

- Il s'agit d'un langage de validation de graphe RDF.
- Les graphes sont compsés de noeuds (ensembles de triplets).
- Validation porte sur la structure et le contenu des noeuds.

Exemple:

```
ex:Alice
    a ex:Person ;
    ex:ssn "987-65-432A" .

ex:Bob
    a ex:Person ;
    ex:ssn "987-65-432B" ;
    ex:birthDate "1971-07-07"^^xsd:date ;
```

SHACL

```
ex:PersonShape
    a sh:NodeShape ;
    sh:targetClass ex:Person ;    # toutes les pesonnes
    sh:property [                 # _:b1
        sh:path ex:ssn ;          # contraintes ex:ssn
        sh:maxCount 1 ;
        sh:minCount 1 ;
        sh:datatype xsd:string ;
    ] ;
    sh:property [                 # _:b2
        sh:path ex:birthDate ;
        sh:maxCount 1 ;
        sh:datatype xsd:date ;
    ] ;
```

Nous allons nous focaliser sur

- Nombre d'occurences:
  - ***sh:minCount*** , ***sh:maxCount***
- Type de noeud:
  - ***sh:NodeKind sh:IRI*** , ***sh:NodeKind sh:BlankNode***
- Type de donnés:
  - ***sh:datatype xsd:date***, ***sh:datatype xsd:string***
- Format
  - ***sh:maxlength 50***
  - ***sh:pattern "^\d{3}\.\d{4}\.\d{4}\.\d{2}$"***

Mode de validation fermé

Pour un noeud donné, le mode fermé (***sh:closed true***), requiert que chaque triplet satisfasse au moins une condition énoncée.

Par défaut, le mode est ouvert. En d'autre termes, les triplets non concernés pas les conditions sont ignorés.

Démonstration

Validateurs en ligne:

- SHACL Play
- SHACL.js

Ou avec un module python (fournit avec le TP3).

Syntaxe pour valider le RDF *dossier.ttl* en utilisant le SHACL shacl.ttl:

```
python shacl.py dossier.ttl shacl.ttl
```
