

HEG-796-22-040

AIPs et OCFL

Jan Krause-Bilvin

2023-05-11

Sessions précédentes

-
- Linked Data Platform (LDP):
 - Ressources (ldp:Ressource) de type RDF et non-RDF
 - Conteneurs (ldp:Container), peuvent être emboîtés
 - Les conteneurs LDP permettent de délimiter les ressources représentant des objets
 - Combinaison d'ontologies, p.ex. RiC-O, PREMIS, SKOS.
 - PREMIS permet de modéliser et organiser la préservation
 - SHACL permet de définir des “shapes”
 - comment les ontologies sont utilisées et combinées
 - de valider la conformité à la définition
-

Cette session

- Archival Information Packages (AIP) : paquets d'information archivistiques (OAIS).
 - Oxford Common File Layout (OCFL) : une spécification pour le stockage des paquets d'information.
 - Lien entre OCFL et LDP.
-

AIPs

Rappel - schéma d'un système de préservation OAIS :

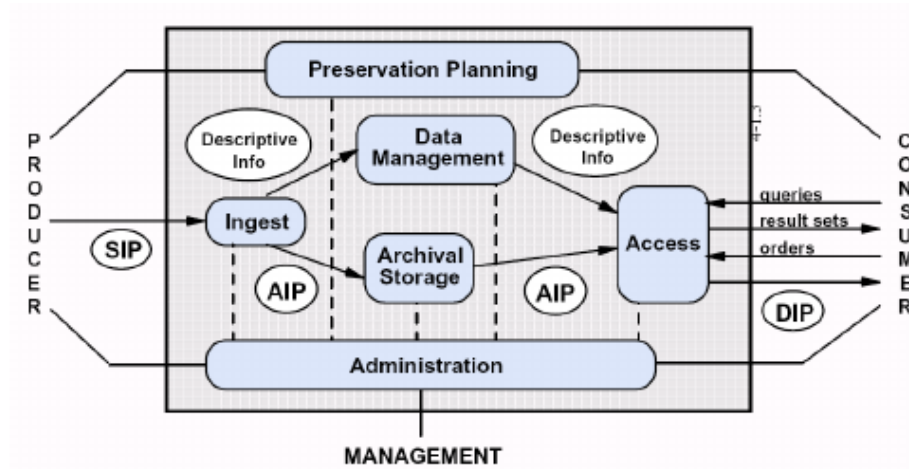
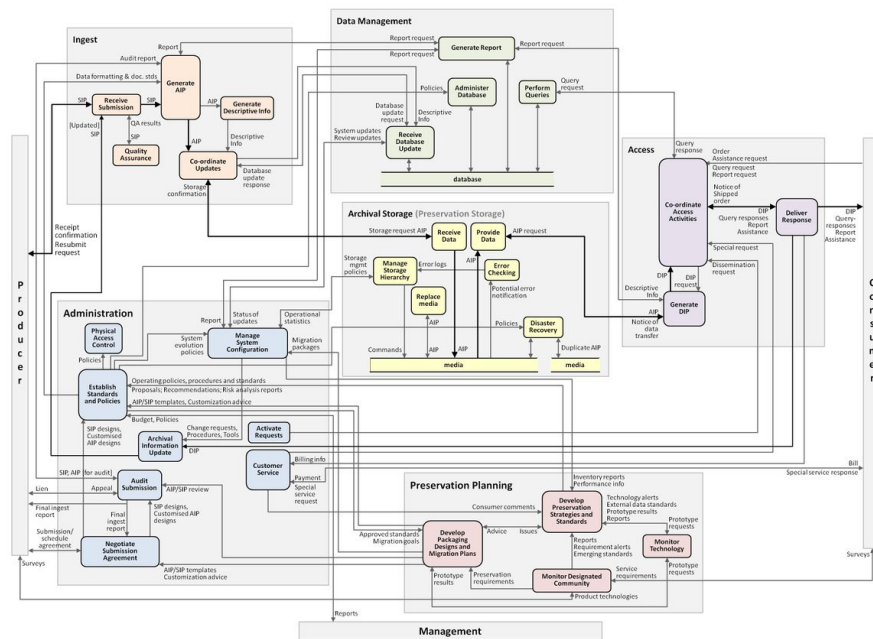


FIGURE 1 – OAIS schema



Representation of 'Figure A-1: Composite of Functional Entities' from the OAIS reference model

FIGURE 2 – OAIS schema full

- Les AIPs sont autonomes : ils contiennent toutes les données et métadonnées d’une “unité archivistique”.
- Au coeur du module de stockage OAIS, ils sont structurés de façon à ce que celui-ci puisse remplir ses fonctions.

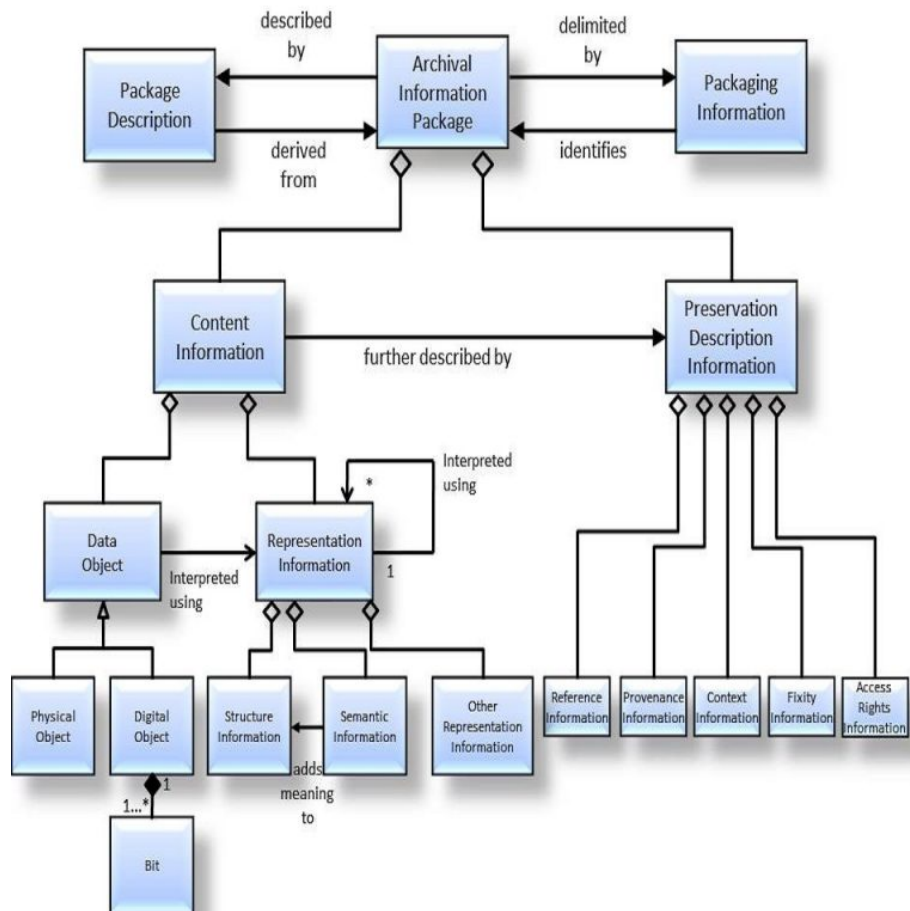


FIGURE 3 – OAIS schema

Cardinalité ContainerLDP - AIP

En théorie, cette cardinalité peut être de m, n .

1. un objet (container LDP) peut être archivé dans un AIP
2. un AIP peut archiver n objets (containers LDP)

Nous allons examiner l'option 2.

Dans Fedora Commons, par défaut, chaque container LDP est stocké comme un seul AIP.

Mais, il est possible d'attribuer la propriété "archival unit" à un container LDP.

Dans ce cas, ce container et tout ses enfants (définis par *ldp:contains*) seront "physiquement" stockés dans le même AIP.

Créer un archival unit dans l'interface de Fedora




FIGURE 4 – Fedora Commons: new archival group

Créer un "archival unit" via l'API

```
import requests
url = 'http://localhost:8080/rest/records/group'
headers = {"Content-Type": "text/turtle",
           "Link": '<http://fedora.info/definitions/v4/repository#ArchivalGroup>;rel="type"'}
auth = ('fedoraAdmin', 'fedoraAdmin')
data = """ <> <rico:title> 'Ceci est le titre'.
          <> <rico:scopeAndContent> 'Voilà la description'.
          """
r = requests.put(url, auth=auth, data=data.encode('utf-8'), headers=headers)
```

```
print( 'Status:', r.status_code )
print( r.text )
```

Noter la partie “link” dans les headers.

OCFL

Oxford Common File Layout est une spécification. Selon ocfl.io :

This Oxford Common File Layout (OCFL) specification describes an application-independent approach to the storage of digital information in a structured, transparent, and predictable manner. It is designed to promote long-term object management best practices within digital repositories.

Toujours selon ocfl.io, ses bénéfices :

- ***Completeness***, so that a repository can be rebuilt from the files it stores
- ***Parsability***, both by humans and machines, to ensure content can be understood in the absence of original software
- ***Robustness*** against errors, corruption, and migration between storage technologies
- ***Versioning***, so repositories can make changes to objects allowing their history to persist
- ***Storage diversity***, to ensure content can be stored on diverse storage infrastructures including conventional filesystems and cloud object stores

En pratique, OCFL définit:

- la hiérarchie de stockage
 - i.e. l'organisation des paquets (objets OCFL) sur le media
- le format des paquets (objets OCFL)
 - i.e. la structure des paquets eux-mêmes

La hiérarchie de stockage OCFL

Elle doit être déterministe. Dans le cas de Fedora Commons, la règle par défaut pour calculer le chemin des paquets est la suivante:

```
hash := sha256( fedoraId )
chemin := hash[0:3]/hash[3:6]/hash[6:9]/hash
```

Exemple:

```
fedoraId = records/acv/dossiers/D1  
chemin = 536/2a8/fe0/5362a8fe0af7fd17596d076f943f179...
```

La structuctue des paquets OCFL

- un répertoire par version v1, v2, v3, ...
 - dans chaque répertoire de version, il y a:
 - un fichier d’inventaire, *inventory.json*, comprenant:
 - maifeste: liste de tous les fichiers avec leur chemin en regard avec leur checksum
 - pour chaque version:
 - liste des fichiers composant la version avec référence au manifeste via le checksum
 - un répertoire *content* avec les fichiers ajoutés ou modifiés dans cette version
-

Exemple 1:

Voir [Exemple_OCFL_inventory.json](#) et [Exemple_OCFL_structure.png](#) :

- v1 : création du paquet avec les fichiers *RiC.ttl* et *IMG_20210228_092707.jpg*
 - v2 : ajout du fichier *cal.txt* et renommage de *IMG_20210228_092707_renomme.jpg*
 - v3 : suppression de *IMG_20210228_092707_renomme.jpg*
 - v4 : modification de *cal.txt*
-

Exemple 2:

Démo :

Exemple d’un dossier dans Fedora Commons.

```

[object root]
├─ 0=ocfl_object_1.0
├─ inventory.json
├─ inventory.json.sha512
├─ v1
│   ├─ inventory.json
│   ├─ inventory.json.sha512
│   └─ content
│       ├─ empty.txt
│       ├─ foo
│       │   └─ bar.xml
│       └─ image.tiff
├─ v2
│   ├─ inventory.json
│   ├─ inventory.json.sha512
│   └─ content
│       └─ foo
│           └─ bar.xml
└─

```

FIGURE 5 – OCFL package: nested content